Pattern Matching

Giuseppe Persiano

Università di Salerno

Primo Semestre

Pattern Matching

Abbiamo due input:

- una stringa T di lunghezza n, il *testo*
- una stringa P di lunghezza m, il *pattern*
  tipicamente, $m \ll n$

Vogliamo trovare tutte le occorrenze di P in T

- cioè tutti gli indici $0 \leq s \leq n - m$ tale che

$$T[s : s + m] = P$$

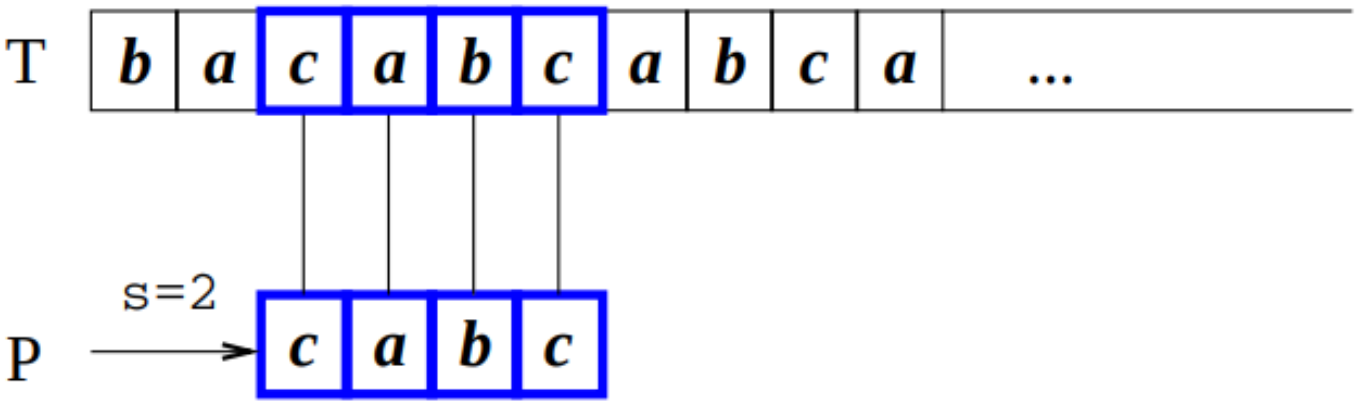

Pattern Matching: Algoritmo di Forza Bruta

- Prova tutti i possibili valori di s
  - per ogni valore prova se tutti i caratteri di P e T sono uguali.
  - se sì s è parte della soluzione
  - altrimenti prova il prossimo s

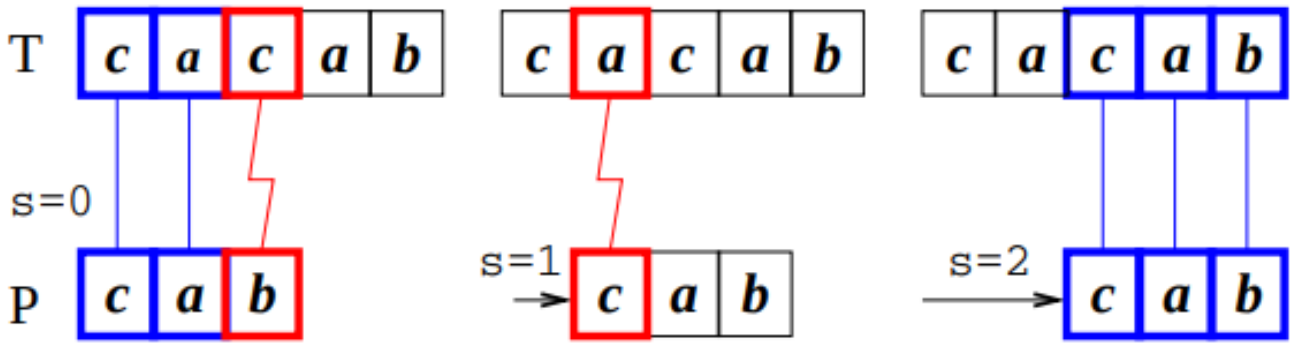

Pattern Matching: Algoritmo di Forza Bruta

```
def bfPM(T,P):
    res=[]
    n=len(T)
    m=len(P)

    for s in range(n-m):
        found=True
        for i in range(m):
            if P[i]!=T[s+i]:
                found=False
                break
        if found:
            res.append(s)
    return res
```

Pattern Matching: Knuth-Morris-Pratt

- L'algoritmo di forza bruta spreca delle informazioni guadagnate con i confronti
- Esempio:

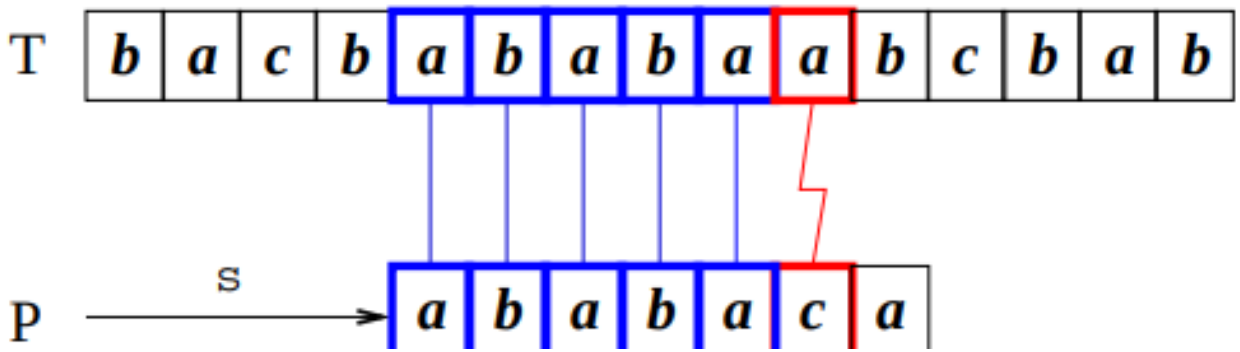

- Inutile fare lo shift di una posizione

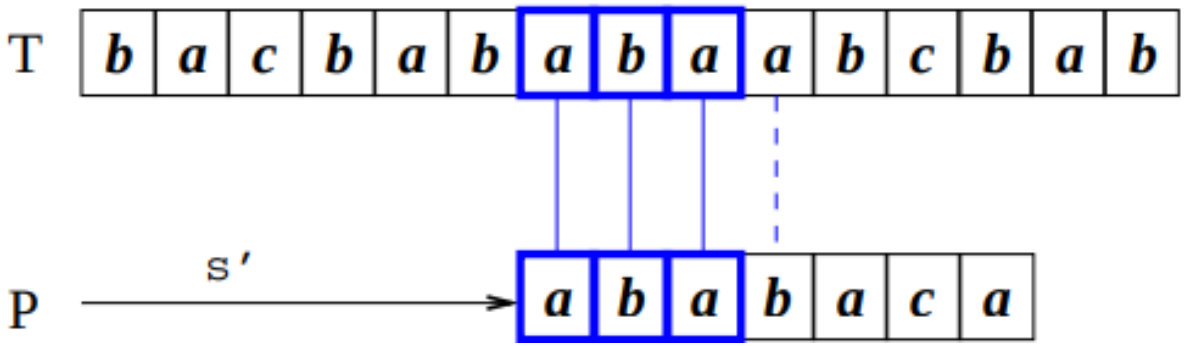

La funzione `next`

- Abbiamo un match parziale

$$P[0 : q] = T[s : s + q]$$

  e poi $P[q] \neq T[s + q]$
- Cerchiamo il più piccolo indice $\sigma > s$ tale che

$$P[0 : k] = T[\sigma : \sigma + k]$$

  con $\sigma + k = s + q$ e quindi

$$P[0 : k] = T[\sigma : s + q]$$

- Nota che $T[\sigma : s + q]$ è uguale ad un suffisso di $P[0 : q]$ quindi cerchiamo
  - il più grande $k < q$ tale

$$P[0 : k] \text{ è suffisso di } P[0 : q]$$

La funzione nxt

- Per un pattern $P[0 : m]$ la funzione

$$\texttt{nxt} : \{0, \ldots, m-1\} \to \{0, \ldots, m-1\}$$

è tale che

$$\texttt{nxt}(q) = \max\{k < q+1 : P[0 : k] \text{ suffisso di } P[0 : q+1]\}$$

- Se abbiamo un match parziale

$$P[0 : q] = T[s : s+q]$$

con $P[q] \neq T[s+q]$, ricominciamo da

$$P[\texttt{nxt}(q-1)]$$

```
def kmpPM(T,P):
    N=len(T)
    M=len(P)
    NXT=calcolaNext(P)
    res=[]
    i=0
    j=0
    while(i<N):
        if (P[j]==T[i]):
            j=j+1
            i=i+1
        if (j==M):
            res.append(i-M)
            j=NXT[j-1]
            continue

        if i<N and P[j]!=T[i]:
            if j!=0:
                j=NXT[j-1]
            else:
                i=i+1
    return res
```